LLM Internals 計算例題集 — 目次

参考: github.com/amitshekhariitbhu/llm-internals ・ 全 24 章 / 50 問 ・ 各問題に「概要 → 問題 → 解説 → 解答」

01 トークナイズと BPE — Tokenization / Byte Pair Encoding

- 01-1 BPE のマージを手計算する
- 01-2 語彙サイズと埋め込み行列のパラメータ数
- 01-3 文字数・単語数・トークン数の換算

02 Attention の Q・K・V — Math behind Attention

- 02-1 X·W で Q, K, V を求める
- 02-2 スコア $Q \cdot K^T$ を計算する
- 02-3 softmax で重みを出し、重み·V で出力を求める

03 $\sqrt{d_k}$ によるスケーリング — Scaling Factor

- 03-1 内積の分散が d_k になることを確かめる
- 03-2 スケーリングの有無で softmax を比べる

04 Causal Mask — Causal Masking

- 04-1 マスク後の softmax を計算する
- 04-2 マスク行列の有効要素数を数える

05 クロスエントロピー損失 — Cross-Entropy Loss

- 05-1 多クラスの CE を計算する
- 05-2 二値の BCE を計算する
- 05-3 勾配 p − y を求める
- 05-4 Perplexity に変換する

06 誤差逆伝播 — Backpropagation

- 06-1 連鎖律で勾配を求める（2層の小さなネット）
- 06-2 勾配降下で重みを更新する

07 Feed-Forward Network — FFN

- 07-1 FFN のパラメータ数（4倍に広げる場合）
- 07-2 ReLU / GELU / SwiGLU の出力を計算する
- 07-3 FFN の FLOPs を数える

08 正規化 — BatchNorm / LayerNorm / RMSNorm

- 08-1 BatchNorm と LayerNorm を同じデータで比べる
- 08-2 RMSNorm を計算し LayerNorm と比べる

09 Transformer 全体 — Transformer Architecture

- 09-1 1 層あたりのパラメータ数
- 09-2 GPT-2 small の総パラメータ数を見積もる

10 KV Cache — KV Cache

- 10-1 KV Cache のメモリ量（GB）
- 10-2 KV Cache の有無で計算量を比べる

11 Paged Attention — Paged Attention

- 11-1 事前確保方式で無駄になるメモリを求める
- 11-2 必要なブロック数と内部断片化

12 Flash Attention — Flash Attention

- 12-1 Online softmax を手計算で追う
- 12-2 HBM の読み書き量を比べる

13 MHA / MQA / GQA — Grouped Query Attention

- 13-1 KV ヘッド数と KV Cache の削減率
- 13-2 GQA でのヘッドのグループ分け

14 RoPE — Rotary Position Embedding

- 14-1 2 次元回転を計算する
- 14-2 内積が相対位置だけで決まることを確かめる

15 LoRA — Low-Rank Adaptation

- 15-1 学習するパラメータの削減率
- 15-2 W + BA のマージを計算する

16 Mixture of Experts — MoE

- 16-1 ルーターの softmax と Top-k の選択
- 16-2 総パラメータ数とアクティブなパラメータ数

17 Speculative Decoding / Medusa / EAGLE — 投機的デコーディング

- 17-1 受理率 α から期待受理トークン数を求める
- 17-2 速度向上率を見積もる

18 Continuous Batching — Continuous Batching

- 18-1 Static と Continuous で GPU 利用率を比べる

19 Prefill と Decode — Inference Optimization

- 19-1 TTFT・TPOT・E2E レイテンシ
- 19-2 算術強度（compute-bound か memory-bound か）

20 Prompt Caching — Prompt Caching

- 20-1 キャッシュの書き込み・読み出しのコストを計算する

21 量子化 — Quantization

- 21-1 FP16 / INT8 / INT4 のメモリ量
- 21-2 INT8 の量子化と逆量子化、誤差

22 サンプリングと停止 — Temperature / Top-k / Stop Token

- 22-1 温度付き softmax
- 22-2 Top-k / Top-p の候補を絞り込む

23 RLHF — Reward Model / KL Penalty

- 23-1 Bradley-Terry 損失
- 23-2 KL ペナルティ付きの報酬

24 LLM ウォーターマーク — Watermarking

- 24-1 Green トークン数から z スコアを求めて判定する