例題 01-2　語彙サイズと埋め込み行列のパラメータ数

これは何？ 何に使う？

何か　トークン ID を d 次元のベクトルに変換する表（ルックアップテーブル）。
出力側の LM Head は逆に、ベクトルを語彙ごとのスコアに戻す。

何のため　ただの番号である ID を、ニューラルネットが計算できる数値ベクトルにするため。
意味の近い単語ほど近いベクトルになるよう学習される。

問題

GPT-2 small は語彙サイズ V = 50,257、埋め込み次元 d = 768 である。
(1) トークン埋め込み行列のパラメータ数はいくつか。
(2) 出力層（LM Head: d → V の線形層、バイアスなし）を埋め込みと
　　共有しない場合、両方を合わせたパラメータ数はいくつか。
(3) (1) の行列を FP16（1 パラメータ 2 バイト）で保存すると何 MB か。

解説

埋め込み行列は「語彙数 × 次元」の表

トークン ID ごとに d 次元のベクトルを 1 行ずつ持つので、形は V × d。

```
50,257 × 768 = 38,597,376  ≈ 38.6 M
```

LM Head は d → V の行列（d × V）

形は転置だが要素数は同じ。共有しなければ 2 倍になる。

```
38,597,376 × 2 = 77,194,752  ≈ 77.2 M
```

GPT-2 は weight tying（共有）を使うので、実際は (1) の分だけで済む。

メモリ量 = パラメータ数 × バイト数

```
38,597,376 × 2 B = 77,194,752 B ≈ 77.2 MB（10⁶ B = 1 MB として）
```

解答

(1) **38,597,376 ≈ 38.6 M**
(2) **77,194,752 ≈ 77.2 M**
(3) **約 77.2 MB**

★ GPT-2 small 全体（約 124 M）の約 3 割が埋め込み行列。語彙を増やすと効いてくる。