例題 02-3　softmax で重みを出し、出力を求める

これは何？ 何に使う？

何か　スコアを softmax で「合計 1 の重み」に変え、Value の加重平均を取る Attention の最後の処理。

何のため　各トークンの表現に、文脈の中で関係の深いトークンの情報を混ぜ込み、「文脈を踏まえた意味」を持つベクトルを作るため。

問題

例題 02-2 のスケーリング後のスコアと、02-1 の V を使う。

$S/\sqrt{2}$ =

0.707	1.414	2.121
0.000	0.707	0.707
0.707	2.121	2.828

V =

1	2
0	1
1	3

(1) 各行に softmax を適用して重み行列 A を求めよ（小数第 3 位まで）。

(2) 出力 Z = A·V を求めよ。

解説

(1) softmax(z)_j = e^{z_j} / Σ_k e^{z_k}（行ごとに計算）

```
1行目: e^0.707=2.028  e^1.414=4.113  e^2.121=8.342  合計 14.483
       → 2.028/14.483=0.140  4.113/14.483=0.284  8.342/14.483=0.576
2行目: e^0=1  e^0.707=2.028  e^0.707=2.028  合計 5.056
       → 0.198  0.401  0.401
3行目: 2.028  8.342  16.918  合計 27.288 → 0.074  0.306  0.620
```

各行の和は 1 になる（確率分布）。

(2) 出力は V の行を重み付きで足したもの

```
z1 = 0.140·(1,2) + 0.284·(0,1) + 0.576·(1,3)
   = (0.140+0+0.576, 0.280+0.284+1.728) = (0.716, 2.292)
z2 = 0.198·(1,2) + 0.401·(0,1) + 0.401·(1,3) = (0.599, 2.000)
z3 = 0.074·(1,2) + 0.306·(0,1) + 0.620·(1,3) = (0.694, 2.314)
```

解答

A ≈

0.140	0.284	0.576
0.198	0.401	0.401
0.074	0.306	0.620

Z = A·V ≈

0.716	2.292
0.599	2.000
0.694	2.314

まとめると **$\mathrm{Attention}(Q,K,V) = \mathrm{softmax}(Q \cdot K^{\mathsf{T}} / \sqrt{d_k}) \cdot V$**。

★ 出力の各行は「全トークンの V の加重平均」。どのトークンをどれだけ混ぜるかを A が決める。

参考: github.com/amitshekhariitbhu/llm-internals