例題 03-1　内積の分散が d_k になることを確かめる

これは何？ 何に使う？

何か　Attention のスコアを √d_k で割る「スケーリング」の理論的な根拠。

何のため　ベクトルの次元 d_k を大きくしても、スコアの散らばりが一定になるようにするため。モデルを大きくしても同じ設定で安定して学習できる。

問題

q と k は d_k 次元のベクトルで、各成分は互いに独立、平均 0・分散 1 とする。

(1) 内積 $q \cdot k = \Sigma\, q_i k_i$ の平均と分散を d_k で表せ。

(2) d_k = 64 と d_k = 512 のとき、q·k の標準偏差はいくつか。

(3) $q \cdot k / \sqrt{d_k}$ の標準偏差はいくつになるか。

解説

(1) 1 項 $q_i k_i$ の平均と分散

q_i と k_i は独立なので、期待値は積に分けられる。

$$E[q_i k_i] = E[q_i] \cdot E[k_i] = 0 \cdot 0 = 0$$

$$Var(q_i k_i) = E[q_i^2 k_i^2] - 0^2 = E[q_i^2] \cdot E[k_i^2] = 1 \cdot 1 = 1$$

（平均 0 なので $E[q_i^2] = Var(q_i) = 1$）

独立な d_k 個の和 → 平均も分散も足し算

$$E[q \cdot k] = 0 \qquad Var(q \cdot k) = 1 + 1 + \dots + 1 = d_k$$

(2) 標準偏差 = √分散

$$d_k = 64 : \sqrt{64} = 8 \qquad d_k = 512 : \sqrt{512} \approx 22.6$$

スコアが ±20 以上に散らばると、softmax がほぼ one-hot になってしまう（03-2）。

(3) 定数 c で割ると分散は $1/c^2$ 倍

$$Var(q \cdot k / \sqrt{d_k}) = d_k / (\sqrt{d_k})^2 = d_k / d_k = 1$$

解答

(1) **平均 0、分散 d_k**

(2) d_k = 64 → **8**、d_k = 512 → **約 22.6**

(3) d_k によらず **1**

★ √d_k で割るのは「次元を増やしてもスコアの散らばりを一定に保つ」ため。