# 例題 03-2　スケーリングの有無で softmax を比べる

## これは何？ 何に使う？

**何か**　スケーリングしたときとしないときで、softmax の出力と勾配がどう変わるかの比較。

**何のため**　softmax が飽和（ほぼ 0 と 1 だけ）になるのを防ぎ、勾配を保って学習を安定させるため。

## 問題

$d_k = 16$ で、あるクエリのスコア（$Q \cdot K^T$ の 1 行）が次のようになった。

```
s = (8, 4, 0)
```

(1) スケーリングなしで softmax(s) を求めよ。

(2) $\sqrt{d_k}$ で割ってから softmax($s / \sqrt{d_k}$) を求めよ。

(3) 最大の重み p について、softmax の勾配の大きさ $p(1-p)$ を比べよ。

## 解説

### (1) そのまま softmax

```
e⁸ = 2981.0  e⁴ = 54.6  e⁰ = 1    合計 3036.6
→ (2981.0, 54.6, 1) / 3036.6 = (0.982, 0.018, 0.0003)
```

ほぼ 1 つのトークンだけに注目する（ほぼ one-hot）。

### (2) $\sqrt{16} = 4$ で割ってから softmax

```
s/4 = (2, 1, 0)
e² = 7.389  e¹ = 2.718  e⁰ = 1    合計 11.107
→ (0.665, 0.245, 0.090)
```

### (3) 勾配 $\partial p / \partial s = p(1-p)$

```
スケーリングなし: 0.982 × 0.018 ≈ 0.018
スケーリングあり: 0.665 × 0.335 ≈ 0.223   （約 12 倍）
```

softmax が飽和すると勾配がほぼ 0 になり、学習が進まなくなる。

## 解答

(1) **(0.982, 0.018, 0.000)**　(2) **(0.665, 0.245, 0.090)**

(3) **約 0.018 と約 0.223**。スケーリングした方が勾配が約 12 倍大きい。

★ スケーリングは「softmax を飽和させず、勾配を流し続ける」ための工夫。