例題 04-1　マスク後の softmax を計算する

これは何？ 何に使う？

何か　Attention で「自分より後ろ（未来）のトークン」を見えなくするマスク。

何のため　次のトークンを予測するときに答えを先に見る「カンニング」を防ぎ、学習時と文章生成時の条件を揃えるため。GPT 型のデコーダでは必須。

問題

デコーダの 3 トークン「私 は 猫」について、スケーリング後のスコア S が次のように出た。

S =

2	1	0
1	3	1
0	2	2

行 i はトークン i（クエリ）、列 j はトークン j（キー）を表す。

(1) Causal Mask を加えたスコア行列を書け。

(2) 各行に softmax を適用して重み行列 A を求めよ（小数第 3 位まで）。

解説

(1) 未来（j > i）のスコアを −∞ にする

生成時、トークン i はまだ出ていない i+1 以降を見てはいけない。

そこで上三角（対角より右上）に −∞ を足す。e^{−∞} = 0 なので重みが 0 になる。

M =

0	-∞	-∞
0	0	-∞
0	0	0

S + M =

2	-∞	-∞
1	3	-∞
0	2	2

(2) −∞ を除いた要素だけで softmax

```
1行目: e² だけ → (1, 0, 0)
2行目: e¹=2.718, e³=20.086 合計 22.804 → (0.119, 0.881, 0)
3行目: e⁰=1, e²=7.389, e²=7.389 合計 15.778 → (0.063, 0.468, 0.468)
```

解答

A ≈

1.000	0	0
0.119	0.881	0
0.063	0.468	0.468

A は**下三角行列**になり、各行の和は 1。

★ 1 行目の「私」は自分自身しか見られないので、重みは必ず 1 になる。
マスクを softmax の「前」に入れるのがポイント（後で 0 にすると行の和が 1 でなくなる）。

参考: github.com/amitshekhariitbhu/llm-internals