例題 04-2　マスク行列の有効要素数を数える

これは何？ 何に使う？

何か　Causal Mask のうち、実際に計算に使われる（マスクされない）要素の数と割合。

何のため　Attention の計算量やメモリを見積もったり、マスクされた部分を飛ばす最適化（Flash Attention など）の効果を見積もったりするため。

問題

系列長 n の Causal Mask を考える。

(1) n = 6 のとき、注目できる（マスクされない）要素数と、マスクされる要素数を求めよ。

(2) 一般の n について、有効要素数を n の式で表せ。

(3) n = 4096 のとき、有効要素は全体の何 % か。

解説

(1) 行ごとに数える

トークン i（1 始まり）は自分を含めて i 個のトークンを見られる。

```
1 + 2 + 3 + 4 + 5 + 6 = 21
```

```
全体 6 × 6 = 36 → マスクされる要素 = 36 − 21 = 15
```

(2) 1 から n までの和

```
1 + 2 + … + n = n(n+1)/2     （対角を含む下三角）
```

(3) 割合

```
n(n+1)/2 ÷ n² = (n+1)/(2n)
```

```
n = 4096: 4097 / 8192 = 0.50012… → 約 50.01 %
```

```
（要素数: 8,390,656 / 16,777,216）
```

解答

(1) 有効 **21**、マスク **15**　(2) **n(n+1)/2**　(3) **約 50.01 %**

★ 長い系列ではスコア行列のほぼ半分が無駄。Flash Attention などは全部が −∞ のブロックを丸ごと飛ばして計算を約半分にする。