例題 06-2　勾配降下で重みを更新する

これは何？ 何に使う？

何か　勾配と逆向きに、重みを少しずつ動かす最適化の方法。

何のため　損失が減る方向に重みを繰り返し更新して、モデルを学習させるため。
LLM で使う Adam / AdamW もこの考え方を発展させたもの。

問題

次の小さなネットワークを考える（バイアスなし）。

$h = \mathrm{ReLU}(w_1 \cdot x) \quad \hat{y} = w_2 \cdot h \quad L = \frac{1}{2}(\hat{y} - t)^2$

入力 $x = 2$、目標 $t = 1$、初期重み $w_1 = 0.5$、$w_2 = 1.5$ とする。

例題 06-1 の勾配 $\partial L/\partial w_1 = 1.5$、$\partial L/\partial w_2 = 0.5$ を使う。

(1) 学習率 $\eta = 0.1$ で 1 ステップ更新した後の w_1, w_2 を求めよ。

(2) 更新後の重みで再び順伝播し、損失 L がどう変わったか確かめよ。

解説

(1) 更新式 $w \leftarrow w - \eta \cdot \partial L/\partial w$

$$w_1 = 0.5 - 0.1 \times 1.5 = 0.5 - 0.15 = 0.35$$

$$w_2 = 1.5 - 0.1 \times 0.5 = 1.5 - 0.05 = 1.45$$

勾配が正 → 重みを減らすと損失が下がる、という向きに動く。

(2) 新しい重みで順伝播

$$h = \mathrm{ReLU}(0.35 \times 2) = 0.7$$

$$\hat{y} = 1.45 \times 0.7 = 1.015$$

$$L = \frac{1}{2}(1.015 - 1)^2 = \frac{1}{2} \times 0.000225 = 0.0001125$$

解答

(1) **$w_1 = 0.35$、$w_2 = 1.45$**

(2) **L: 0.125 → 約 0.00011**（予測 1.5 → 1.015 で目標 1 にほぼ一致）

★ 学習率が大きすぎると行き過ぎて発散し、小さすぎると収束が遅い。
LLM の学習もこの「順伝播 → 逆伝播 → 更新」を何兆トークン分も繰り返している。