LLMを手計算する ― 3トークンで「次の1語」を予測し、1回だけ学習する

入力「猫 が 寝る」→ 正解の次トークン「。」 設定: d_model = 4, d_k = 2, 語彙 = {猫, が, 寝る, 。}, アテンション1ヘッド

流れ: 埋め込み → RMSNorm → Q·K·V → RoPE → スコア/√d_k + 因果マスク → softmax → 重み付き和 → ロジット → 交差エントロピー → 逆伝播 → 勾配降下

① 埋め込み X と RMSNorm

各トークンのベクトルを RMS（二乗平均の平方根）で割って大きさをそろえる（γ = 1, ε は省略）

X（埋め込み）

猫	1	1	1	−1
が	2	−2	2	2
寝る	3	1	−1	1

→ RMS

猫	1
が	2
寝る	1.73

→ X̂ = X / RMS

猫	1	1	1	−1
が	1	−1	1	1
寝る	1.73	0.58	−0.58	0.58

例) 寝る: RMS = √((3² + 1² + (−1)² + 1²) / 4) = √3 ≈ 1.73 → 3 / 1.73 = 1.73, 1 / 1.73 = 0.58

② Q・K・V を作る（行列の掛け算）

Q = X̂·W_Q, K = X̂·W_K, V = X̂·W_V （W は学習で決まる重み。ここでは簡単な値）

W_Q

1	0
0	1
1	0
0	1

W_K

0	1
1	0
1	0
0	1

W_V

1	0
0	1
0	1
1	0

Q

猫	2	0
が	2	0
寝る	1.15	1.16

K

猫	2	0
が	0	2
寝る	0	2.31

V

猫	0	2
が	2	0
寝る	2.31	0

例) Q(寝る) = [1.73·1 + 0.58·0 + (−0.58)·1 + 0.58·0, 0.58·1 + 0.58·1] = [1.15, 1.16]

Q = 「自分は何を探しているか」, K = 「自分は何を持っているか」, V = 「渡す中身」

③ RoPE: 位置 m に応じて Q と K を回転させる（V は回転しない）

角度 = m·θ（θ = 1 rad）。 [a, b] → [a·cos − b·sin, a·sin + b·cos]。回転後の内積は相対位置（n − m）だけで決まる

位置と回転

	m	cos m	sin m
猫	0	1	0
が	1	0.54	0.84
寝る	2	−0.42	0.91

Q' = RoPE(Q)

猫	2	0
が	1.08	1.68
寝る	−1.54	0.56

K' = RoPE(K)

猫	2	0
が	−1.68	1.08
寝る	−2.10	−0.97

例) Q(が), m = 1: [2·0.54 − 0·0.84, 2·0.84 + 0·0.54] = [1.08, 1.68]

④ アテンションスコア: Q'·K'ᵀ を √d_k で割り、未来のトークンを隠す（因果マスク）

LLM は左から右へ生成するので、各トークンは自分より前（と自分）しか見られない → 右上を −∞ にする

S = Q'·K'ᵀ

	猫	が	寝る
猫	4	−3.36	−4.20
が	2.16	0	−3.90
寝る	−3.08	3.19	2.69

÷ √2 →

S / √d_k + マスク

	猫	が	寝る
猫	2.84	−∞	−∞
が	1.53	0	−∞
寝る	−2.18	2.26	1.91

例) S(寝る→が) = (−1.54)·(−1.68) + 0.56·1.08 = 2.59 + 0.60 = 3.19 → 3.19 / 1.41 = 2.26

√d_k で割るのは、次元が大きいと内積の分散が d_k 倍に膨らみ、softmax が 0/1 に張り付くのを防ぐため

⑤ softmax で重みにして、V を混ぜる

各行で e^s を計算し、行の合計で割る（−∞ は e^−∞ = 0）。その重みで V の行を足し合わせたものが出力 H

A = softmax(行ごと)

	猫	が	寝る
猫	1	0	0
が	0.82	0.18	0
寝る	0.01	0.58	0.41

× V

猫	0	2
が	2	0
寝る	2.31	0

= H = A·V

猫	0	2
が	0.36	1.64
寝る	2.11	0.02

例) 寝る行: e^−2.18 = 0.11, e^2.26 = 9.58, e^1.91 = 6.75, 合計 16.44 → [0.01, 0.58, 0.41]

h(寝る) = 0.01·[0, 2] + 0.58·[2, 0] + 0.41·[2.31, 0] = [2.11, 0.02]

⑥ 次トークンの確率と交差エントロピー損失

最後のトークン「寝る」の出力 h を語彙行列 W_out に掛けてロジット z → softmax で確率 p → 損失 L = −ln p(正解)

h(寝る)

2.11	0.02

× W_out

	猫	が	寝る	。
	1	0	−1	1
	0	1	1	1

= z（ロジット）

猫	が	寝る	。
2.11	0.02	−2.09	2.13

p = softmax(z)

猫	が	寝る	。
0.46	0.06	0.01	0.47

学習前の予測確率



例) z(。) = 2.11·1 + 0.02·1 = 2.13, p(。) = e^2.13 / (8.25 + 1.02 + 0.12 + 8.41) = 8.41 / 17.80 = 0.47

損失 L = −ln 0.47 = 0.76 （正解の確率が 1 に近いほど 0 に近づく）

⑦ 逆伝播と勾配降下: W_out を 1 回だけ更新する

softmax + 交差エントロピーの勾配は ∂L/∂z = p − y（y は正解の one-hot）。連鎖律で ∂L/∂W_out = hᵀ·(p − y)。学習率 α = 0.5

∂L/∂z = p − y

猫	が	寝る	。
0.46	0.06	0.01	−0.53

∂L/∂W_out = hᵀ·(p − y)

	猫	が	寝る	。
h_1	0.97	0.13	0.02	−1.12
h_2	0.01	0	0	−0.01

W_out ← W_out − 0.5·∂L/∂W_out

猫	が	寝る	。
0.52	−0.07	−1.01	1.56
−0.01	1	1	1

更新後の p

猫	が	寝る	。
0.10	0.03	0	0.87

学習後の予測確率



例) ∂L/∂W_out[1,。] = 2.11 × (0.47 − 1) = −1.12 → 1 − 0.5·(−1.12) = 1.56

結果: p(。) 0.47 → 0.87, 損失 L 0.76 → 0.14 正解「。」の確率が上がった！

※ 残差接続・FFN・マルチヘッド・W_Q/W_K/W_V 等への逆伝播は省略。各段階の値は小数第2位に丸め、丸めた値で次の計算をしている。

参考: Amit Shekhar「Math Behind Large Language Model」シリーズ（outcomeschool.com）。数値例はこの図のために独自に作成。